

Modelar el Caos: Predicción de Arribos en un Sistema Urbano Complejo

Matteo Musacchio, Tiziano Demarco
mmusacchio@udesa.edu.ar, demarcot@udesa.edu.ar

OBJETIVO Desarrollar un modelo que permita anticipar la cantidad de bicicletas que llegarán a cada estación de Ecobici en los próximos ΔT minutos, usando información de los viajes iniciados en los pasados ΔT minutos.	DATASET Se utilizaron registros públicos del sistema Ecobici entre 2020 y 2024. Cada entrada representa un viaje, con información sobre estación origen y destino, duración, usuario y tipo de bicicleta.	ABSTRACT El comportamiento del sistema es complejo e inherentemente estocástico, pero la existencia de patrones locales temporales y espaciales que permiten aproximar a una predicción útil. La incorporación de contexto histórico mejora levemente la precisión.
--	---	---

Análisis exploratorio

- Se eliminaron viajes anómalos, como aquellos de duración menor a un minuto o años inconsistentes.
- Se analizaron patrones horarios, detectando alta variabilidad según la hora del día.
- Se exploraron posibles flujos entre estaciones, aunque no se observaron agrupamientos claros, evidenciando la complejidad del sistema.

Preprocesamiento y Arquitectura

Se construyó un dataset de series temporales, donde cada fila representa una estación en un intervalo de 30 minutos.

DATASET ORIGINAL → **Preprocess** → **FEATURES X**

- Variables temporales: año, mes, día, hora
- Cantidad de viajes iniciados
- Información de la estación
- Datos de los usuarios: edad, género

MODELO
XG Boost, Light GBM, DenseNN

XGBoost

f2(x) → **f1(x)**

PREDICCIONES
Cantidad de arribos en el siguiente intervalo

$\hat{y} = \sum_{k=1}^n f_k(x)$


hasta $fn(x)$

$g_i = \frac{\partial \ell}{\partial \hat{y}_i}, \quad h_i = \frac{\partial^2 \ell}{\partial \hat{y}_i^2}$

para construir cada arbol

$L = \sum_{i=1}^N \ell(y_i, \hat{y}_i) + \Omega(f)$


- El flujo de viajes sigue patrones similares entre años, pero la cantidad varía significativamente entre meses dentro de cada año.



Distribución mensual de viajes por cada año del dataset

- Esto sugiere que entrenar modelos diferenciados por estación del año o por rangos de meses podría capturar mejor la estacionalidad y mejorar la capacidad predictiva frente a un único modelo global.


- La mayoría de los viajes se concentran en cierto rango horario específico, que por la forma de procesamiento de datos genera muchas ventanas horarias con actividad nula o muy baja.



Intensidad de viajes por hora del día

- Esto produce una matriz de entrada dispersa, que si bien refleja el flujo real, complica el entrenamiento del modelo y su rendimiento al diluir la información útil.

- En la matriz de adyacencia notamos una estructura dispersa, sin patrones de alta correlación entre estaciones específicas, Indicando que no existen relaciones fuertes de dependencia directa entre ellas.



Matriz de adyacencia entre estaciones (cantidad de viajes entre pares de estaciones) en escala logarítmica

- Sugiere que el problema de predicción de arribos resulta complejo. Las dinámicas entre estaciones no presentan estructuras claras que faciliten su anticipación con modelos simples.

Resultados

Modelo	MAE	R2
XGBoost	0.41	0.42
XG + Lag Features	0.39	0.44
XG Poisson + Lag	0.37	0.45
LightGBM	0.40	0.43
DenseNN	0.39	0.44

Resultados de los modelos en dataset de validación

XGBoost modelado a Poisson con features de lag

Importancia de Features

Predicciones versus valores reales para el conjunto de validación

- El modelado de Poisson con XGBoost ayudó a adaptar las predicciones, aunque con alta dispersión debido al nivel elevado de ruido en el target
- Las features de lag generadas figuran entre las más relevantes, indicando que aportaron información valiosa al modelo.
- Aún así, el mal rendimiento de las métricas indica que, dada la naturaleza estocástica del sistema, no será posible lograr predicciones de alta precisión con la información disponible.

Conclusiones y Trabajo futuro

- Predicción limitada por la alta variabilidad** del sistema y la escasa estructura entre estaciones.
- XGBoost con pérdida de Poisson** e incorporación de lags fue la estrategia más efectiva.
- Trabajo futuro:** Adoptar otro enfoque para la organización del problema como segmentar modelos por horarios o estaciones específicas, y sumar datos externos como clima, eventos o turismo para capturar mejor la variabilidad.